Aprendizado de Máquina Supervisionado – IMD3202

Aula 01 – Apresentação da disciplina e do conteúdo programático

João Carlos Xavier Júnior
jcxavier@imd.ufrn.br

INSTITUTO METRÓPOLE DIGITAL

PPgTI

Apresentação dos Docentes

- Prof. João Carlos Xavier Júnior
  - Sala: B309 (2º andar do IMD)
  - E-mail: jcxavier@imd.ufrn.br
  - Horário de atendimento: segundas, quartas e sextas pela manhã.
- Pesquisa:
  - Mineração de Texto;
  - Técnicas de Aprendizado de Máquina;
  - Algoritmos Evolutivos.

http://lattes.cnpq.br/5088238300241110

Objetivos da Disciplina

- A disciplina de **Aprendizado de Máquina** tem como objetivos:
  - Transmitir o **conhecimento teórico** e **prático** necessário para que possam fazer uso das técnicas de **Aprendizagem de Máquina**;
  - Estimular o **trabalho em equipe**, a **experimentação**, a **comprovação prática** dos conceitos aprendidos e a superação frente a desafios que serão colocados no decorrer da disciplina.

Aprendizado de Máquina

- É um área da **computação** dedicada ao desenvolvimento e construção **de técnicas** que possibilitem **o computador** (Máquina ou Programa) **aprender**, isto é, ser capaz de cumulativamente aperfeiçoar seu desempenho na realização de alguma tarefa, de forma autônoma e independente.

Aprendizado de Máquina

- Existem basicamente duas formas de aprendizado:
  - **INDUTIVO**, que extrai conhecimento (regras e padrões) dos próprios dados e;
  - **DEDUTIVO**, que faz uso de premissas, observações da natureza e fatos do mundo real, para então inferir uma conclusão.

Aprendizado de Máquina

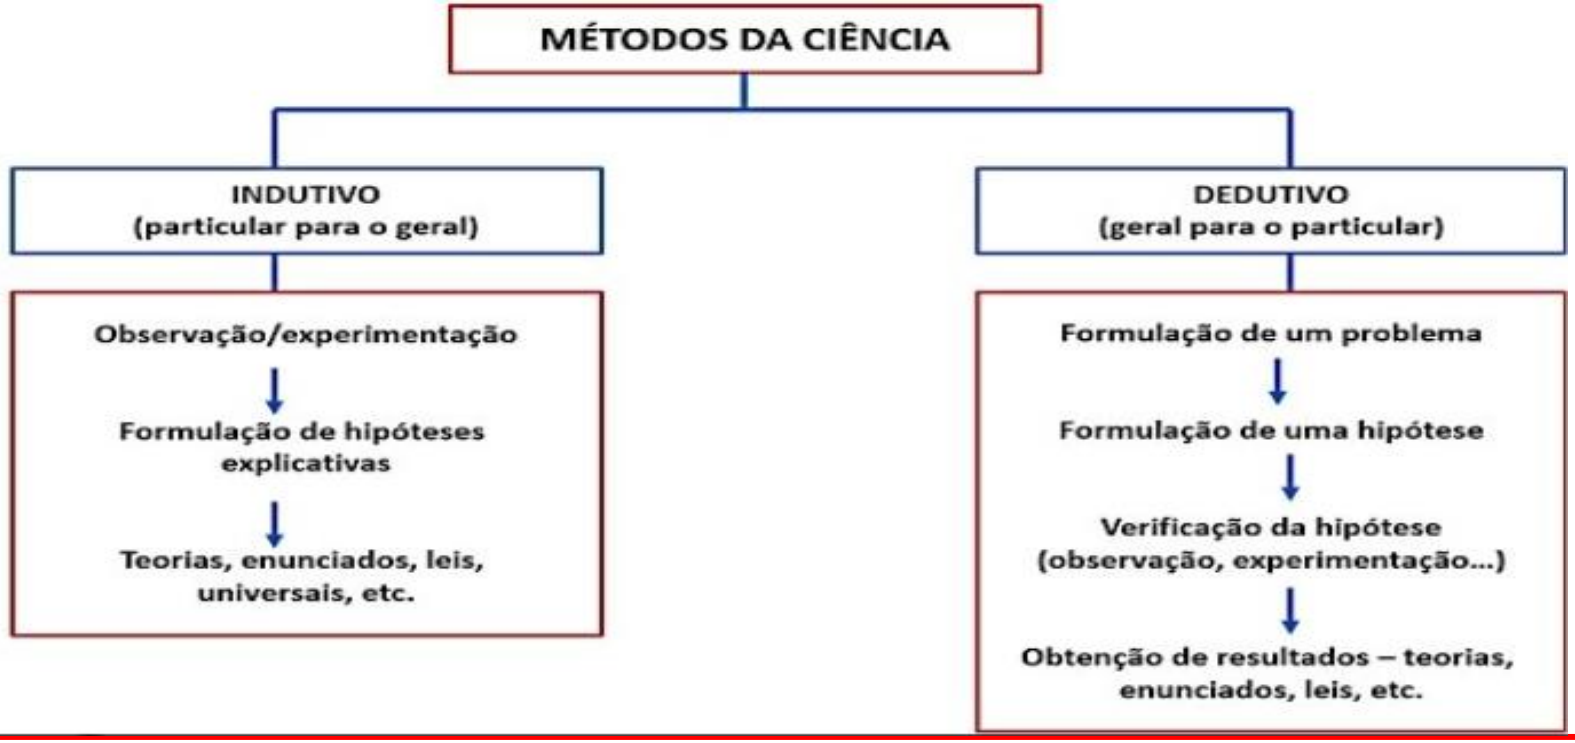

Aprendizado de Máquina faz uso apenas da **forma indutiva** para extração automática do conhecimento.

Sumário da Disciplina

- Aprendizado de Máquina Supervisionado:
  - Conceitos
  - Descritores
  - Testes Estatísticos
- Modelos de indutores:
  - Supervisionados
- Sistemas de Combinação de indutores:
  - Supervisionados

Bibliografia

- Faceli, Katti, Ana Carolina Lorena, João Gama & André C.P.L.F. de Carvalho (2011), **Inteligência Artificial: uma Abordagem de Aprendizado de Máquina**, LTC – Livros técnicos e científicos Editora Ltda.

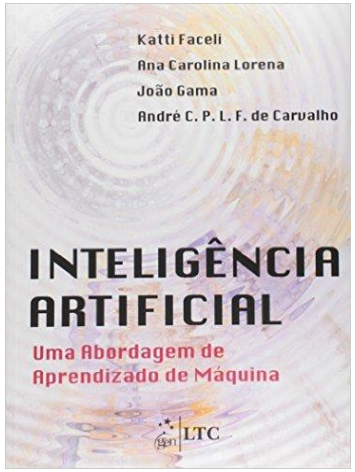

- Witten, I.H. & Frank, E. & Hall, M.A. & Pal, C.J. (2016). **Data Mining: practical machine learning tools and techniques**.

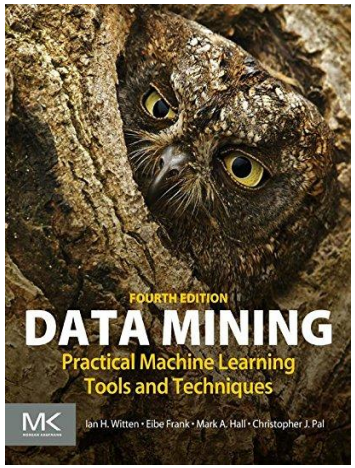

Cronograma de Aulas

Aula01: Apresentação da disciplina	03/03/2026
Aula02: Aprendizado de Máquina	05/03/2026
Não Haverá Aula	07/03/2026
Aula03: Pré-processamento (conceituação, limpeza e transformação)	10/03/2026
Aula04: Pré-processamento (redução de dados - sampling)	12/03/2026
Aula05: Pré-processamento (prática de limpeza e transformação)	13/03/2026
Não Haverá Aula	14/03/2026
Aula06: Pré-processamento (redução de dimensionalidade 01)	17/03/2026
Aula07: Pré-processamento (redução de dimensionalidade 02)	19/03/2026
Aula08: Pré-processamento (prática de PCA e seleção de atributos)	20/03/2026
Aula09: Aplicação de HOG (base de imagens - prática 01)	24/03/2026
Aula10: Aplicação de LBP (base de imagens - prática 02)	26/03/2026
Aula11: Prática de processamento de imagens	27/03/2026
Aula12: Técnica de Treinamento e Teste - Validação cruzada	31/03/2026

Cronograma de Aulas

Aula13: Algoritmo supervisionado (k-NN)	07/04/2026
Aula14: Prática de k-NN	09/04/2026
Aula15: Algoritmo supervisionado (Árvore de Decisão)	14/04/2026
Aula16: Prática de AD	16/04/2026
Aula17: Algoritmo supervisionado (Naive Bayes)	23/04/2026
Aula18: Prática de NB	28/04/2026
Aula19: Modelos supervisionados (Redes Neurais 01)	30/04/2026
Aula20: Modelos supervisionados (Redes Neurais 02)	05/05/2026
Aula21: Prática de Redes Neurais	07/05/2026
Aula22: Avaliação de Aprendizagem	12/05/2026
Aula23: Teste estatístico (teoria e prática)	14/05/2026
Aula24: Comitês de classificadores	19/05/2026

Cronograma de Aulas

Aula25: Prática de Comitês de classificadores	21/05/2026
Aula26: Elaboração do Projeto 01	26/05/2026
Aula27: Seleção e Utilização de Modelos (Transfer Learning)	28/05/2026
Aula28: Modelos supervisionados (Deep Learning)	02/06/2026
Aula29: Elaboração do Projeto 02	09/06/2026
Aula30: Elaboração do Projeto 03	11/06/2026
Aula31: Elaboração do Projeto 04	16/06/2026
Aula32: Apresentação de Projetos 01	18/06/2026
Aula33: Apresentação de Projetos 02	23/06/2026
Aula34: Apresentação de Projetos 03	25/06/2026
Aula35: Apresentação de Projetos 04	30/06/2026
Aula36: Apresentação de Projetos 05	02/07/2026
Não Haverá Aula	07/07/2026
Prova de Reposição	09/07/2026

Processo Avaliativo

Avaliações

- Avaliações de conteúdo (teórica).
  - 1ª unidade
- Atividades Práticas.
  - 2ª unidade
- Projeto de Aprendizado de Máquina:
  - 3ª unidade
  - Individual ou Dupla.

Procedimento de Avaliação

- Avaliação de conhecimento:
  - Questões objetivas e dissertativas sobre o conteúdo ministrado.
  - Objetivo: verificar se conteúdo foi absorvido pelos alunos.

Processo Avaliativo

- Avaliação de conteúdo:
  - Relatório/Artigo(formato SBC) especificando os passos aplicados sobre uma base de dados (metodologia e resultados).
    - Grupo: individual ou dupla.
  - Atividades práticas (aplicação dos conceitos)
    - Tarefas cadastradas no SIGAA.

Processo Avaliativo

- Relatório/Artigo(formato SBC):
  - Elaboração de artigo técnico sobre extratores de características para imagens e aplicação de técnicas de Aprendizado de Máquina Supervisionado.
  - Seções obrigatórias (Resumo, Abstract, Introdução, Conceitos Relacionados, ○ Descrição do problema e Base de Dados (concentrando nos atributos); Metodologia dos Experimentos, Resultados Experimentais, Sugestões para melhoria dos experimentos ou dificuldades encontradas, Conclusão e Referências).
  - Só aceitarei artigos em PDF e submetidos via **SIGAA**.

Processo Avaliativo

- Relatório/Artigo(formato SBC):

Uso de Técnicas de Aprendizado de Máquina Supervisionado junto aos Extratores de Características LBP e HOG

[redacted]

[1]Instituto Metrópole Digital - Universidade Federal do Rio Grande do Norte (UFRN)
Código Postal 59078-900 - Av. Capitão-Mor Gouveia, S/N - Lagoa Nova - Natal - RN - Brazil

[redacted]

Abstract. *This work addresses the study encompassing supervised machine learning, specifically in the area of image pattern identification and recognition, in an attempt to simulate the human capacity to categorize objects and living beings. This is done through experiments using different classification model training techniques, allowing for the evaluation of results and difficulties encountered during the process. The results obtained show that among the simple techniques, the best is MLP (Multilayer Perceptron), and among the committees, Voting was inferior to the others, which are statistically similar to each other. Comparing the best simple technique with the best committee, we find that they have no statistical difference.*

Resumo. *Este trabalho aborda o estudo que abrange o aprendizado de máquina supervisionado, especificamente no que tange à área de identificação e reconhecimento de padrões em imagens, numa tentativa de simular essa capacidade humana de categorizar objetos e seres vivos. Isso é feito através de experimentos utilizando diferentes técnicas de treinamento de modelos de classificação, permitindo avaliar os resultados e as dificuldades encontradas durante o processo. Os resultados obtidos mostram que entre as técnicas simples, a melhor delas é o MLP (Multilayer Perceptron), e entre os comitês o Voting foi inferior aos demais que são estatisticamente semelhantes entre si. E comparando a melhor técnica simples com o melhor comitê, temos que eles não possuem diferença estatística.*

1. Introdução

A capacidade de reconhecer padrões e formas é uma habilidade imprescindível para os seres vivos por tornar mais fácil e prática a navegação no mundo. Em particular, essa capacidade envolve a classificação e padronização de objetos e animais. E essa habilidade pode oferecer grande suporte no dia a dia, permitindo identificar animais que podem ser perigosos ou dóceis, por exemplo.

Assim, procurando simular essa habilidade presente na maioria dos animais, existem muitas pesquisas que procuram reproduzir a capacidade de reconhecer imagens utilizando aprendizado de máquina. E para esse propósito são utilizados algoritmos robustos, que capturam padrões e características presentes nas imagens.

Neste trabalho, são divulgados diversos experimentos realizados com técnicas de aprendizado de máquina supervisionado voltadas ao reconhecimento de imagens. E

1

18

Processo Avaliativo

- Relatório/Artigo(formato SBC):

Abstract. *This work addresses the study encompassing supervised machine learning, specifically in the area of image pattern identification and recognition, in an attempt to simulate the human capacity to categorize objects and living beings. This is done through experiments using different classification model training techniques, allowing for the evaluation of results and difficulties encountered during the process. The results obtained show that among the simple techniques, the best is MLP (MultiLayer Perceptron), and among the committees, Voting was inferior to the others, which are statistically similar to each other. Comparing the best simple technique with the best committee, we find that they have no statistical difference.*

Resumo. *Este trabalho aborda o estudo que abrange o aprendizado de máquina supervisionado, especificamente no que tange à área de identificação e reconhecimento de padrões em imagens, numa tentativa de simular essa capacidade humana de categorizar objetos e seres vivos. Isso é feito através de experimentos utilizando diferentes técnicas de treinamento de modelos de classificação, permitindo avaliar os resultados e as dificuldades encontradas durante o processo. Os resultados obtidos mostram que entre as técnicas simples, a melhor delas é o MLP (MultiLayer Perceptron), e entre os comitês o Voting foi inferior aos demais que são estatiscamente semelhantes entre si. E comparando a melhor técnica simples com o melhor comitê, temos que eles não possuem diferença estatística.*

1. Introdução

A capacidade de reconhecer padrões e formas é uma habilidade imprescindível para os seres vivos por tornar mais fácil e prática a navegação no mundo. Em particular, essa capacidade envolve a classificação e padronização de objetos e animais. E essa habilidade pode oferecer grande suporte no dia a dia, permitindo identificar animais que podem ser perigosos ou dóceis, por exemplo.

Processo Avaliativo

- Relatório/Artigo(formato SBC):

2. Descrição do problema e Base de Dados

O trabalho consistiu no uso de técnicas de Aprendizado de Máquina para identificar espécies de animais (gatos e cahorros) através de imagens fornecidas pelo Ther Oxford-IIIT Dataset [Parkhi et al. 2012]. Para este projeto foram selecionadas as seguintes raças para cada espécie: Egyptian Mau e Russian Blue para gatos; Saint Bernard e Shiba Inu para cães.

3. Pré-processamento

Para o pré-processamento das imagens do experimento, a base inicial, formada por aproximadamente 800 imagens distribuídas igualmente entre as raças de gatos e cachorros (proporção 25:25:25:25), foi transformada em 13 bases de dados. As imagens foram redimensionadas para 128x128, 256x256 e 512x512 pixels e manipuladas utilizando os algoritmos HOG, LBP e, quando aplicável dado um número suficiente de atributos, o PCA. Cada instância, ao ser guardada nas bases, foi rotulada como sendo 'cat' ou 'dog', transformando o problema que tinha uma saída de 4 classes para um binário.

4. Metodologia dos Experimentos

A metodologia foi dividida em duas partes, cada uma com seus experimentos individuais, sendo as partes Técnicas de Aprendizado de Máquina Supervisionado e Comitês de Classificadores, respectivamente. Em ambas as partes, os treinamentos foram feitos utilizando tanto k-fold CV quanto 70/30 holdout, e métrica usada para verificar os desempenhos foi o F1-Score.

Processo Avaliativo

- Relatório/Artigo(formato SBC):

5. Resultados experimentais

Os resultados foram dispostos em tabelas que mostram a métrica F1 Score, como mencionado anteriormente. Também foram realizados os testes estatísticos de Friedman e de Nemenyi, o último apenas quando o primeiro indicava haver diferença estatística entre os resultados para então achar onde estava essa diferença. Os resultados se encontram nas subseções abaixo:

			Decision TreeClassifier									
#	Base	Treinamento/Teste	Conf. 1	Conf. 2	Conf. 3	Conf. 4	Conf. 5	Conf. 6	Conf. 7	Conf. 8	Conf. 9	Conf. 10
	Metodologias		F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE	F1-SCORE
1	HOG_128_32x32 (324 atributos)	10-fold CV	0,648	0,622	0,638	0,636	0,617	0,649	0,6	0,617	0,622	0,645
		70/30	0,644	0,632	0,572	0,663	0,631	0,633	0,640	0,606	0,644	0,626
2	HOG_128_32x32_PCA-TSVD (35 atributos)	10-fold CV	0,6	0,612	0,615	0,616	0,61	0,604	0,622	0,630	0,602	0,598
		70/30	0,640	0,679	0,664	0,664	0,606	0,615	0,630	0,655	0,640	0,598
3	HOG_128_36x36 (144 atributos)	10-fold CV	0,624	0,651	0,636	0,632	0,622	0,615	0,604	0,638	0,619	0,622
		70/30	0,590	0,609	0,622	0,621	0,586	0,519	0,611	0,603	0,577	0,533
4	HOG_128_40x40 (144 atributos)	10-fold CV	0,591	0,641	0,616	0,615	0,612	0,582	0,626	0,602	0,602	0,583
		70/30	0,607	0,593	0,661	0,605	0,619	0,631	0,648	0,628	0,615	0,650
5	HOG_256_64x64 (324 atributos)	10-fold CV	0,624	0,639	0,61	0,616	0,636	0,645	0,641	0,65	0,64	0,638
		70/30	0,674	0,653	0,652	0,648	0,644	0,644	0,64	0,64	0,64	0,64
6	HOG_256_64x64_PCA-TSVD (35 atributos)	10-fold CV	0,598	0,588	0,582	0,58	0,602	0,586	0,637	0,606	0,593	0,552
		70/30	0,590	0,593	0,661	0,618	0,586	0,585	0,579	0,598	0,586	0,610
7	HOG_256_80x80 (144 atributos)	10-fold CV	0,614	0,612	0,575	0,592	0,593	0,588	0,684	0,603	0,586	0,588
		70/30	0,640	0,639	0,585	0,597	0,651	0,627	0,617	0,623	0,627	0,631
8	HOG_256_96x96 (36 atributos)	10-fold CV	0,611	0,619	0,627	0,62	0,62	0,632	0,629	0,625	0,631	0,625
		70/30	0,640	0,682	0,610	0,629	0,657	0,648	0,665	0,653	0,682	0,653
9	HOG_512_128x128 (324 atributos)	10-fold CV	0,613	0,612	0,591	0,599	0,63	0,597	0,607	0,614	0,611	0,601
		70/30	0,569	0,589	0,625	0,651	0,560	0,648	0,533	0,619	0,582	0,631
10	HOG_512_128x128_PCA-TSVD (35 atributos)	10-fold CV	0,606	0,61	0,615	0,614	0,617	0,624	0,607	0,61	0,597	0,62
		70/30	0,560	0,584	0,567	0,659	0,577	0,559	0,569	0,615	0,577	0,559
11	HOG_512_150x150 (144 atributos)	10-fold CV	0,601	0,605	0,587	0,596	0,6	0,609	0,616	0,617	0,62	0,604
		70/30	0,596	0,628	0,587	0,601	0,603	0,573	0,593	0,565	0,607	0,577
12	HOG_512_182x182 (36 atributos)	10-fold CV	0,592	0,642	0,601	0,598	0,593	0,613	0,626	0,624	0,593	0,612
		70/30	0,557	0,577	0,661	0,661	0,596	0,644	0,569	0,594	0,590	0,619
#	Média =>		0,607	0,612	0,610	0,616	0,611	0,615	0,617	0,619	0,609	0,611
	Desv. Pad =>		0,027573	0,035767	0,025247	0,027145	0,022553	0,03284	0,031026	0,021616	0,024606	0,029482

Processo Avaliativo

- Relatório/Artigo(formato SBC):

6. Discussão e dificuldades encontradas

Podemos ver pelos resultados dos experimentos que a técnica com melhor desempenho foi o MLP, enquanto o comitê foi o Stacking. Um fato interessante é que o k-NN, ainda que uma técnica muito simples, conseguiu que a média de desempenho de seus modelos fosse maior que as das técnicas Árvore de Decisão e Naive Bayes.

Nenhum dos modelos treinados conseguiu chegar a 0.8 de desempenho, sendo o melhor o Stacking (5) com F1 Score de 0.741, ou seja, acertando aproximadamente 3 de 4 classificações. Por outro lado não houve nenhum modelo com um desempenho pior do que 0.6, tendo o pior F1 Score de 0.607, então nossos modelos ainda são melhores do que simplesmente escolher uma classe ao acaso.

7. Conclusão

Este trabalho teve como objetivo aplicar e avaliar as diferentes técnicas de aprendizado de máquina supervisionado para classificar aproximadamente 800 imagens de gatos (das raças Egyptian Mau e Russian Blue) e cachorros (Saint Bernard e Shiba Inu), identificando e validando os resultados obtidos através delas.

Processo Avaliativo

- Relatório/Artigo(formato SBC):

Referências

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.

Parkhi, O. M., Vedaldi, A., Zisserman, A., & Jawahar, C. (2012). *Cats and Dogs*. CVPR.

Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). *Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns*. IEEE TPAMI.

Dalal, N., & Triggs, B. (2005). *Histograms of Oriented Gradients for Human Detection*. CVPR.

Sokolova, M., & Lapalme, G. (2009). *A Systematic Analysis of Performance Measures for Classification Tasks*. Information Processing & Management.

Kohavi, R. (1995). *A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection*. IJCAI.

Demšar, J. (2006). *Statistical Comparisons of Classifiers over Multiple Data Sets*. Journal of Machine Learning Research.

Processo Avaliativo

- Artigo (formato SBC): onde encontrar?

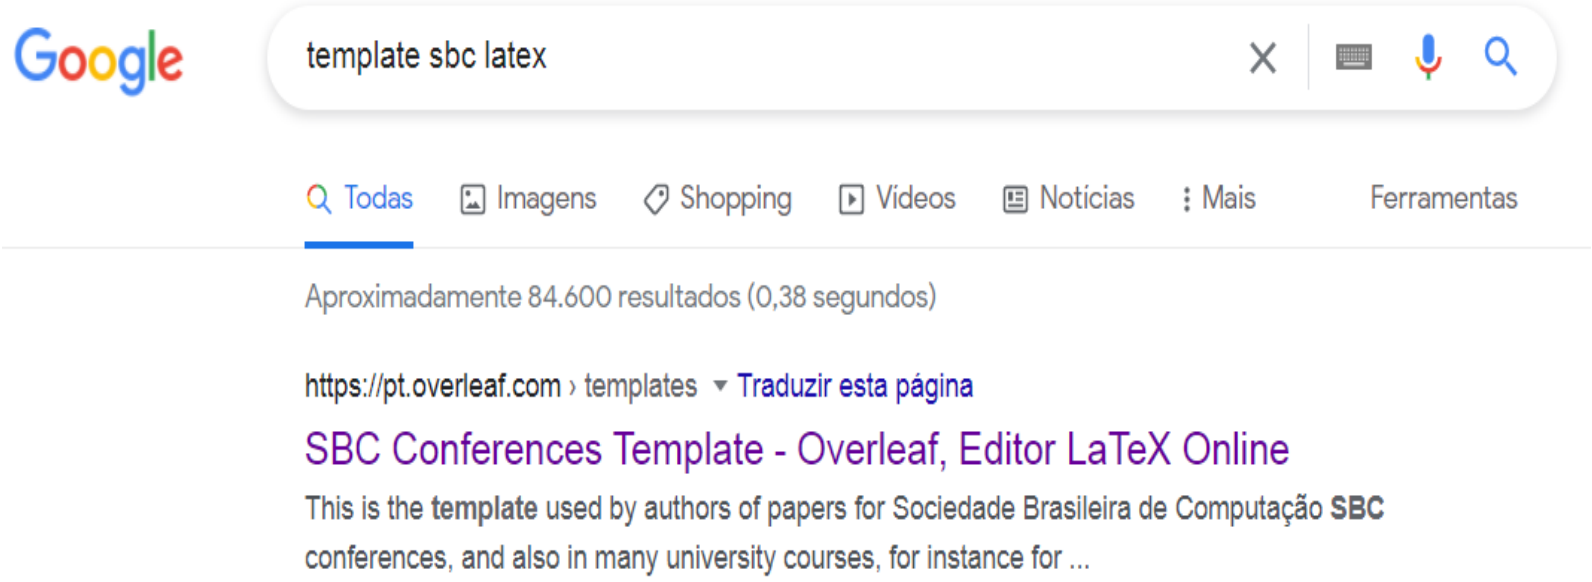

Processo Avaliativo

- Artigo (formato SBC): onde encontrar?

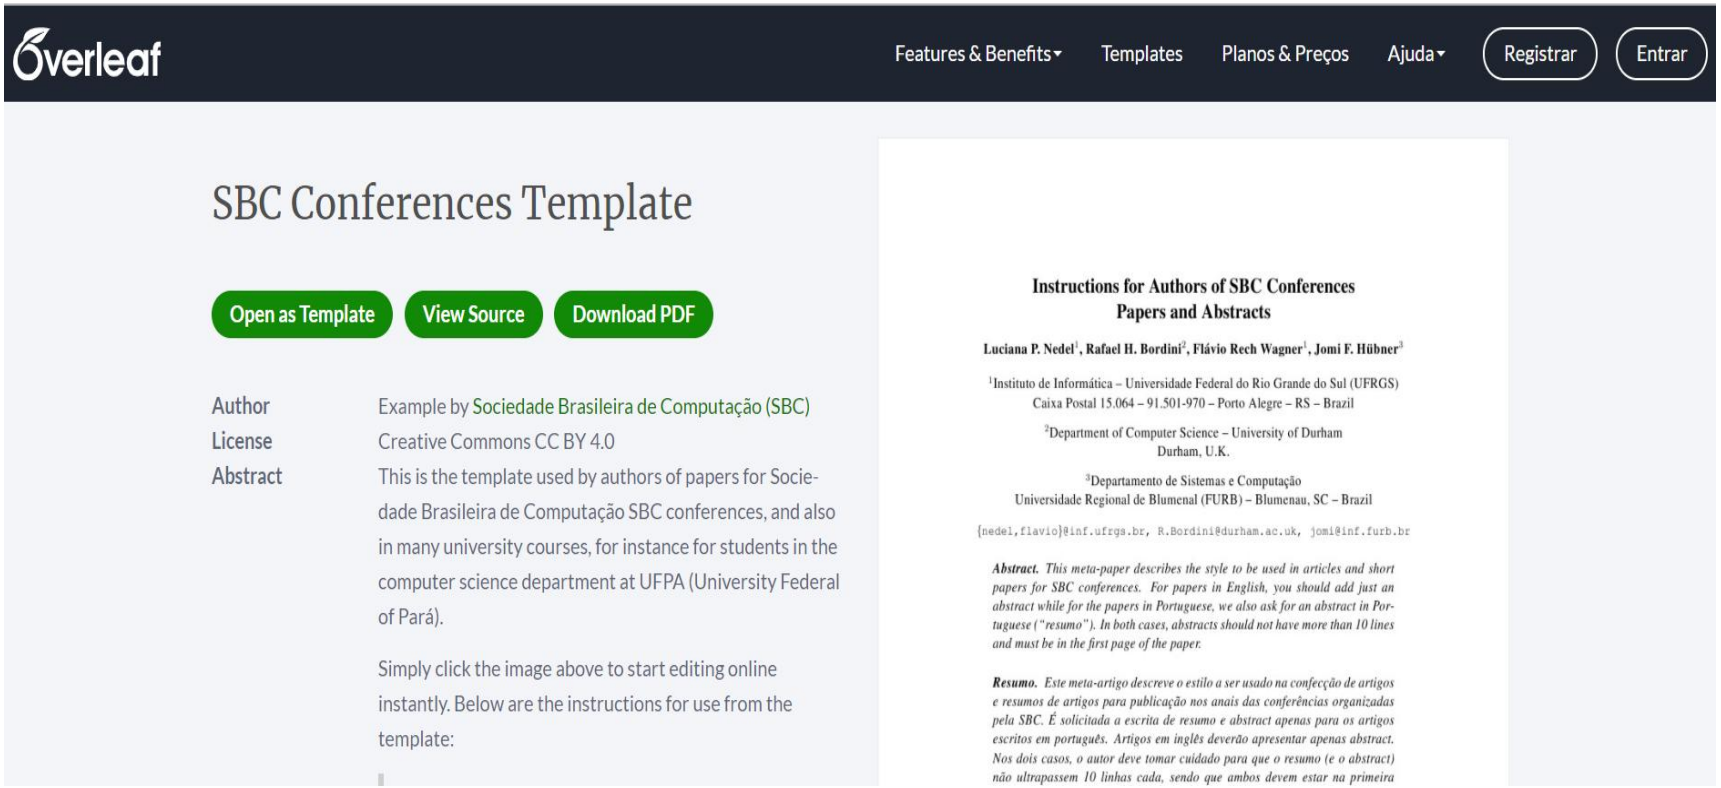

https://pt.overleaf.com/latex/templates/sbc-conferences-template/blbxwjwzdngr

Processo Avaliativo

- Apresentação (elaboração de slides):

Análise comparativa de classificadores para distinção de raças de Cães e Gatos

Utilizando Características LBP e HOG

Processo Avaliativo

- Apresentação (elaboração de slides):

Pré - processamento

LBP (Local Binary Patterns)

Descreve texturas comparando cada pixel com vizinhos. Dimensões: 256×256 com raios 3, 6 e 12.

- Captura padrões de intensidade
- Eficiente computacionalmente
- 51 a 27 atributos gerados

HOG (Histogram of Oriented Gradients)

Analisa bordas e contornos através de distribuições de gradientes. Dimensões: 128×128 e 256×256.

- Reconhecimento de formas
- Tamanhos de célula: 16×16, 20×20, 32×32
- 325 a 1765 atributos gerados

Processo Avaliativo

- Apresentação (elaboração de slides):

Metodologia

01

Pré-processamento

Conversão para escala de cinza. Extração com LBP e HOG gerando 35 bases de dados.

02

Seleção de Bases

Melhor base : PCA HOG 128 32x32 70% (27 atributos).
KNN com Holdout (70/30) e K-Fold (10 folds). Selecionadas 12 melhores bases por F1-Score.

03

Utilização dos demais classificadores

Árvore de decisão, Naïve Bayes e MLP aplicados nas nossas 12 melhores bases .
Calculado F1 Score médio é desvio padrão.

04

Testes estatísticos e comitê de classificadores

Testes estatísticos (Friedman e Nemenyi).
Bagging, Random Forest, Voting e Stacking com configurações otimizadas dos modelos base.

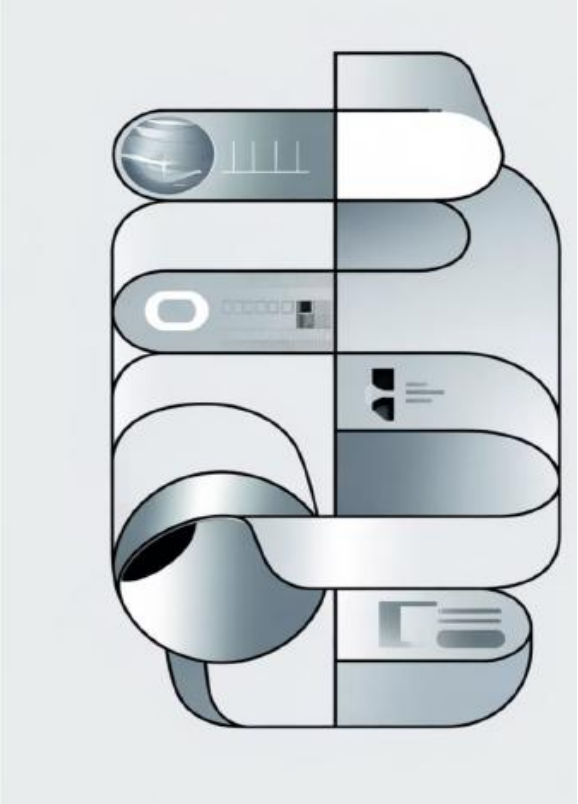

Processo Avaliativo

- Apresentação (elaboração de slides):

Resultados: Classificadores Individuais

0,6278

KNN (k=10)

Melhor configuração com F1-Score médio. Desempenho inferior entre os quatro.

0,6280

Decision Tree

Configuração 1 (gini, profundidade 4). Desempenho moderado com custo computacional baixo.

0,6890

Naive Bayes

GaussianNB superior. Equivalente estatisticamente ao MLP ($p > 0,05$).

0,6880

MLP

Configuração 1 (activation: 'tanh', hidden-layer-sizes: 100, learning-rate-init: 0.001, max-inter: 1500, solver: 'adam') com menor desvio padrão (0,0285). Mais estável e consistente.

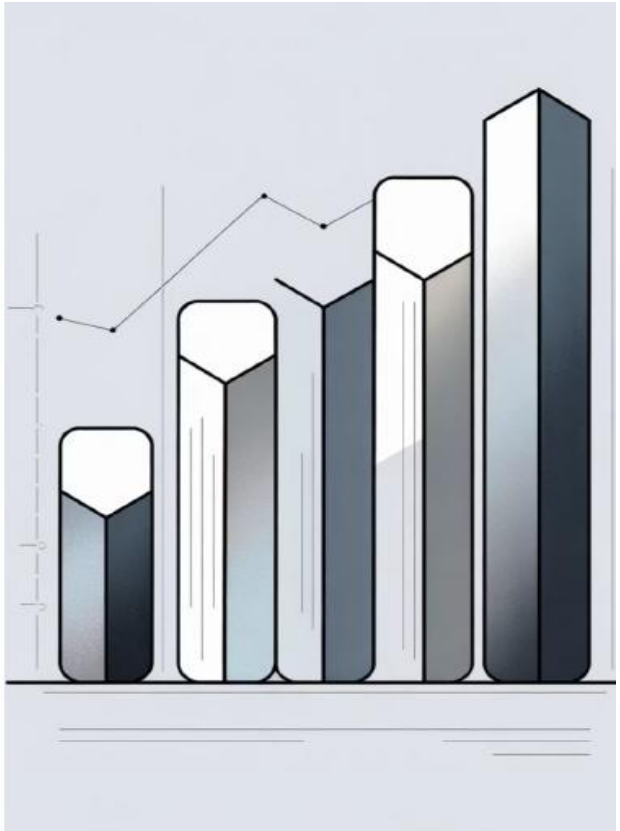

Processo Avaliativo

- Apresentação (elaboração de slides):

Análise Estatística: Testes de Friedman e Nemenyi

Teste de Friedman

Rejeitou hipótese nula ($p < 0,05$) para todos os classificadores, confirmando diferenças significativas globais entre as configurações testadas.

Teste de Nemenyi (Pós-hoc)

Identificou dois grupos: Naive Bayes e MLP (alto desempenho) versus KNN e Decision Tree (desempenho inferior).

→ MLP selecionado como melhor classificador individual por apresentar menor variabilidade (desvio padrão 0,0285) e melhor capacidade de modelar complexidade em dados de imagem.

Processo Avaliativo

- Apresentação (elaboração de slides):

Dificuldades encontradas

- Geração de 35 bases de dados distintas
- Alto custo computacional (até 1 hora por execução)
- Otimização de múltiplos hiper parâmetros
- Seleção de melhores configurações

Processo Avaliativo

- Apresentação (elaboração de slides):

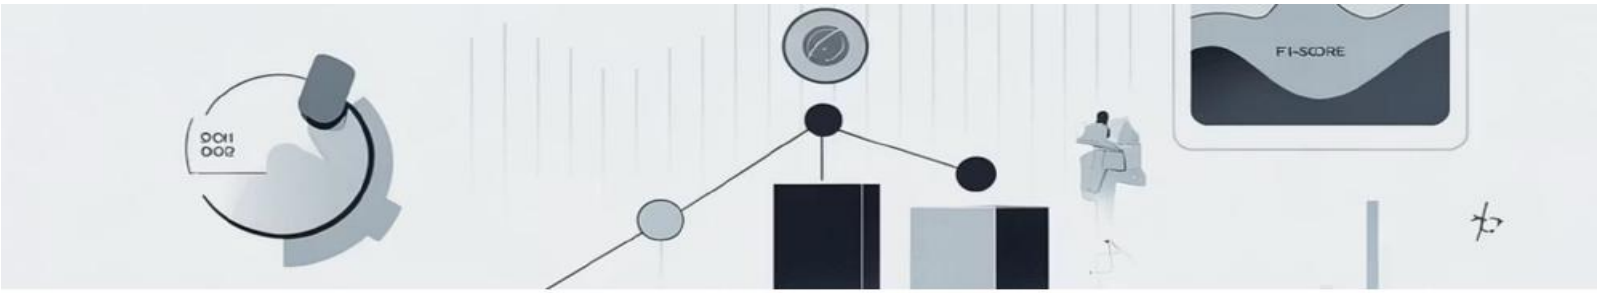

Conclusão

→ **Melhor Classificador Individual**

MLP com F1-Score 0,6880 e menor variabilidade (0,0285), superior em estabilidade ao Naive Bayes apesar de equivalência estatística.

→ **Melhor Final**

MLP: Levando em consideração suas caracteristicas e as validações aplicadas.

→ **Melhor Ensemble**

Stacking com 20 classificadores alcançou F1-Score 0,7011, superando todos os demais modelos também nos testes estatísticos.

Projeto da Disciplina

- **The Oxford-IIIT Pet Dataset:**

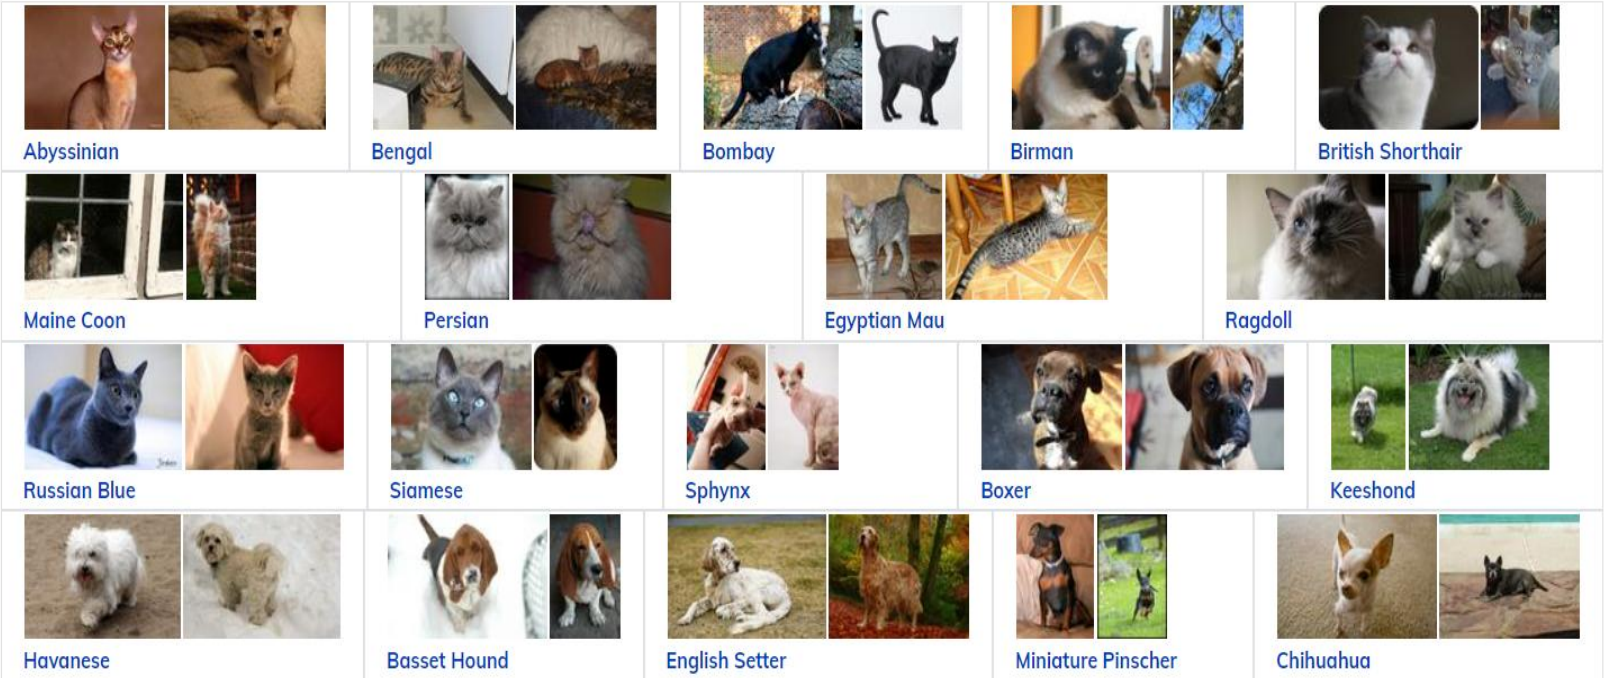

Downloads

The Oxford-IIIT Pet dataset and annotations are roughly 800 MB in size and available for download via BitTorrent with Academic Torrents:

- Torrent (faster download) for dataset and groundtruth

https://www.robots.ox.ac.uk/~vgg/data/pets/

Projeto da Disciplina

- **The Oxford-IIIT Pet Dataset:**

Dataset Statistics

Breed	Count
American Bulldog	200
American Pit Bull Terrier	200
Basset Hound	200
Beagle	200
Boxer	199
Chihuahua	200
English Cocker Spaniel	196
English Setter	200
German Shorthaired	200
Great Pyrenees	200
Havanese	200
Japanese Chin	200
Keeshond	199
Leonberger	200
Miniature Pinscher	200
Newfoundland	196
Pomeranian	200
Pug	200
Saint Bernard	200
Samyoed	200
Scottish Terrier	199
Shiba Inu	200
Staffordshire Bull Terrier	189
Wheaten Terrier	200
Yorkshire Terrier	200
Total	4978

1.Dog Breeds

Breed	Count
Abyssinian	198
Bengal	200
Birman	200
Bombay	200
British Shorthair	184
Egyptian Mau	200
Main Coon	190
Persian	200
Ragdoll	200
Russian Blue	200
Siamese	199
Sphynx	200
Total	2371

2.Cat Breeds

Family	Count
Cat	2371
Dog	4978
Total	7349

3.Total Pets

Projeto da Disciplina

- **Proposta (trabalho de AM):**

Individual ou dupla

Com **quatro** classes, **duas** das espécies de **cachorro** e **duas** das espécies de **gato**

Requisitos

- Espera-se que o aluno possua ou se disponha a adquirir individualmente uma bagagem de conhecimento que inclua:
  - Conceitos de Probabilidade e Estatística;
  - Programação (Python).

Perguntas ...

Obrigado!!!